Programa Ciencia de los Datos
Big Data
Tarea 3 – Spark ML

---

1. Integrantes del grupo

Nombre completo	Cédula
Dana Chavarría Corrales	402670050

2. Archivos necesarios para ejecutar el código

La estructura de archivos necesaria para ejecutar el proyecto es la siguiente:

```
T3/
├── big-data/
│   └── Dockerfile
├── data/
│   └── bank.csv
├── notebooks/
│   └── tarea3.ipynb
├── output/
├── docker-compose.yaml
├── README.md
└── Tarea3.md
```

Conjunto de datos: *Bank Marketing*, del UCI Machine Learning Repository. El archivo utilizado es bank.csv. La variable objetivo es y, que indica si el cliente contrata un depósito a plazo.

3. Instrucciones de ejecución

3.1. Requisitos

Para ejecutar el proyecto se necesita lo siguiente:

- Tener instalado Docker Desktop o Docker Engine con el complemento Docker Compose y verificar que esté en ejecución.
- Disponer de los puertos 8888 (Jupyter) y 5433 (PostgreSQL, para consultas externas).
- Contar con conexión a internet durante la primera ejecución para construir la imagen.
- Tener acceso a una terminal. El procedimiento descrito fue probado en Windows utilizando PowerShell.

3.2. Pasos de ejecución

Paso 1. Descargar y descomprimir el archivo ZIP en un directorio local.

Paso 2. Abrir una terminal y ubicarse en la carpeta T3, donde se encuentra el archivo docker-compose.yaml.

Paso 3. Construir y levantar los contenedores de PostgreSQL y Jupyter con Spark mediante el siguiente comando:

```
docker compose up -d --build
```

La primera ejecución puede tardar varios minutos, debido a que es necesario construir la imagen.

Paso 4. Verificar que los servicios estén activos:

```
docker compose ps
```

El servicio postgres debe aparecer como *healthy* y el servicio big-data debe estar en ejecución.

Paso 5. Obtener el enlace de acceso a Jupyter con el token de autenticación: docker compose logs bigdata
Buscar la línea que contiene una dirección similar a la siguiente: http://127.0.0.1:8888/tree?token=...
Paso 6. Abrir en el navegador la dirección obtenida.
Paso 7. Abrir la carpeta notebooks y seleccionar el archivo tarea3.ipynb.
Paso 8. Ejecutar todas las celdas del notebook desde el menú **Kernel** → **Restart Kernel and Run All Cells**. Al finalizar, las celdas deben mostrar sus respectivas salidas.

3.3. Conexión a PostgreSQL

La conexión a PostgreSQL está configurada en el archivo docker-compose.yaml. Los parámetros son los siguientes:

Parámetro	Valor
Host desde el notebook	postgres
Puerto desde el notebook	5432
Base de datos	tarea3db
Usuario	spark
Contraseña	spark123

El notebook obtiene estos valores a partir de las variables de entorno configuradas en el contenedor, por lo que no se requiere una configuración adicional.

4. Tablas generadas en la base de datos

Al ejecutar el notebook, se crean las siguientes tablas en PostgreSQL. Se utiliza el modo `overwrite